SubFabric ASR 三长度横评（2026-10-21）

速度 · 置信度 · WER · 说话人分离 —— 基于人工精校 ASS 的本机横评

素材:	How I Saved the World's Largest Minecraft Server.webm（前 30 秒 / 5 分钟 / 10 分钟）
参考:	人工精校的字幕（前两小时）.ass（只取 Default 英文行，去掉颜色标签与逐词重复行）
机器:	RTX 4060 Laptop 8GB + Intel Arc 核显 + Intel AI Boost NPU，Windows，Node 24
口径:	片段都从 0 秒开始；WER 忽略大小写/标点/连字符，数字转英文词；不做术语表修复与语义分句。

结论摘要

终稿优先：Whisper large-v2（5/10min WER 8.73% / 8.92%，10min 约 3.1×）。**速度优先**：Parakeet CUDA + 置信度关闭（10min 13.25×，WER 10.67%）。**仅粗剪**：Parakeet NPU（最快 27.3×，但 WER 约 23%，明显漏词）。**VibeVoice**：30s 在 900s 上限未完成，长片段不可用。**说话人分离**：10min 约 201s，开启后总倍率降到 1.5–2.7×，按需开启。

结果总表

片段	模型	配置	识别耗时	识别×	分离耗时	总耗时	总×	平均置信度	低置信占比	WER
30s	Parakeet NPU	置信度关闭	5.76s	5.21×	7.19s	12.95s	2.32×	0.859	0%	1.22%
30s	Parakeet CUDA	置信度关闭	6.58s	4.56×	7.19s	13.77s	2.18×	0.882	0%	3.66%
30s	Parakeet NPU	置信度完整	8.36s	3.59×	7.19s	15.55s	1.93×	0.846	0%	1.22%
30s	Parakeet CUDA	置信度完整	13.85s	2.17×	7.19s	21.04s	1.43×	0.873	0%	3.66%
30s	Whisper large-v2	逐词关闭	28.7s	1.05×	7.19s	35.89s	0.84×	—	—	6.1%
30s	Whisper large-v2	置信度完整	29.41s	1.02×	7.19s	36.6s	0.82×	0.811	0%	1.22%
30s	Multitalker Parakeet	单说话人模式	34.42s	0.87×	7.19s	41.61s	0.72×	—	—	3.66%
30s	VibeVoice	置信度完整	-	-	-	-	-	-	-	-
30s	Qwen3-ASR + 对齐	ASR 文本 + 强制对齐	12.325s	2.43×	-	12.325s	2.43×	-	-	2.44%
30s	Whisper + 对齐	Whisper 文本 + 强制对齐	33.558s	0.89×	-	33.558s	0.89×	-	-	1.22%
30s	Canary-1B-Flash	CUDA · 单次	34.173s	0.88×	-	34.173s	0.88×	-	-	3.66%
30s	Canary-1B-v2	CUDA · 单次	7.571s	3.96×	-	7.571s	3.96×	-	-	4.88%

片段	模型	配置	识别耗时	识别×	分离耗时	总耗时	总×	平均置信度	低置信占比	WER
30s	Parakeet-TDT-1.1B	CUDA · 单次	14.6s	2.05×	-	14.6s	2.05×	-	-	3.66%
30s	Whisper large-v3	CUDA · 逐词开	24s	1.25×	-	24s	1.25×	-	-	3.66%
30s	Paraformer-en	CUDA · 单次	9.073s	3.31×	-	9.073s	3.31×	-	-	8.54%
30s	Granite Speech 2B	CUDA · 单次	12.129s	2.47×	-	12.129s	2.47×	-	-	3.66%
30s	Granite Speech 8B	8GB 显存不足未测	-	-	-	-	-	-	-	-
30s	GLM-ASR-Nano-2512	CUDA · 单次	8.764s	3.42×	-	8.764s	3.42×	-	-	6.1%
30s	Fun-ASR-Nano-2512	CUDA · 单次	19.014s	1.58×	-	19.014s	1.58×	-	-	3.66%
30s	Index-Echo-S2TT-2B	Q8_0 仅文本 / 完整 10GB>8GB	-	-	-	-	-	-	-	-
30s	Granite Speech 5.0 470M	CUDA · CTC	2.215s	13.54×	-	2.215s	13.54×	-	-	6.10%
30s	Parakeet-TDT-0.6B-v3	CUDA · TDT	4.146s	7.24×	-	4.146s	7.24×	-	-	2.44%
30s	Nemotron 3.5 ASR 0.6B	CUDA · RNNT	4.868s	6.16×	-	4.868s	6.16×	-	-	8.54%
30s	MOSS-Transcribe-Diarize 0.9B	CUDA · 音频 LLM	18.274s	1.64×	-	18.274s	1.64×	-	-	3.66%
30s	Canary-Qwen 2.5B	CUDA · NeMo SALM	46.088s	0.65×	-	46.088s	0.65×	-	-	3.66%
300s	Parakeet NPU	置信度关闭	11.95s	25.11×	116.08s	128.03s	2.34×	0.733	14%	22.84%
300s	Parakeet NPU	置信度完整	19.09s	15.71×	116.08s	135.17s	2.22×	0.64	29%	22.84%
300s	Parakeet CUDA	置信度关闭	21.15s	14.18×	116.08s	137.23s	2.19×	0.806	7%	9.07%
300s	Parakeet CUDA	置信度完整	75.09s	4×	116.08s	191.17s	1.57×	0.789	7%	9.07%
300s	Whisper large-v2	置信度完整	81.99s	3.66×	116.08s	198.07s	1.51×	0.74	16%	8.73%
300s	Whisper large-v2	逐词关闭	95.82s	3.13×	116.08s	211.9s	1.42×	—	—	10.19%
300s	Multitalker Parakeet	单说话人模式	281.31s	1.07×	116.08s	397.39s	0.75×	—	—	13.44%
300s	VibeVoice	置信度完整	-	-	-	-	-	-	-	-
300s	Qwen3-ASR + 对齐	ASR 文本 + 对齐 · 2×150s	61.257s	4.90×	-	61.257s	4.90×	-	-	9.07%
300s	Whisper + 对齐	Whisper 文本 + 对齐 · 2×150s	96.013s	3.12×	-	96.013s	3.12×	-	-	10.08%
300s	Canary-1B-Flash	长音频 900s 未完成	-	-	-	-	-	-	-	-
300s	Canary-1B-v2	CUDA device-side assert	-	-	-	-	-	-	-	-
300s	Parakeet-TDT-1.1B	CUDA · 单次	115.963s	2.59×	-	115.963s	2.59×	-	-	12.21%
300s	Whisper large-v3	CUDA · 逐词开	74s	4.05×	-	74s	4.05×	-	-	10.19%
300s	Paraformer-en	ONNX Mul 广播错误	-	-	-	-	-	-	-	-

片段	模型	配置	识别耗时	识别×	分离耗时	总耗时	总×	平均置信度	低置信占比	WER
300s	Granite Speech 2B	长音频 900s 未完成	-	-	-	-	-	-	-	-
300s	Granite Speech 8B	8GB 显存不足未测	-	-	-	-	-	-	-	-
300s	GLM-ASR-Nano-2512	长音频输出错乱（WER 77%）	-	-	-	-	-	-	-	-
300s	Fun-ASR-Nano-2512	长音频输出截断	-	-	-	-	-	-	-	-
300s	Index-Echo-S2TT-2B	Q8_0 仅文本 / 完整 10GB>8GB	-	-	-	-	-	-	-	-
300s	Granite Speech 5.0 470M	CUDA · CTC	1.922s	156.09×	-	1.922s	156.09×	-	-	12.77%
300s	Parakeet-TDT-0.6B-v3	CUDA · TDT	11.348s	26.44×	-	11.348s	26.44×	-	-	10.64%
300s	Nemotron 3.5 ASR 0.6B	CUDA · RNNT	18.737s	16.01×	-	18.737s	16.01×	-	-	15.23%
300s	MOSS-Transcribe-Diarize 0.9B	CUDA · 音频 LLM	185.161s	1.62×	-	185.161s	1.62×	-	-	9.18%
300s	Canary-Qwen 2.5B	长音频输出错乱	-	-	-	-	-	-	-	-
600s	Parakeet NPU	置信度关闭	21.96s	27.32×	200.98s	222.94s	2.69×	0.76	11%	22.98%
600s	Parakeet NPU	置信度完整	42.44s	14.14×	200.98s	243.42s	2.46×	0.683	17%	22.98%
600s	Parakeet CUDA	置信度关闭	45.29s	13.25×	200.98s	246.27s	2.44×	0.837	5%	10.67%
600s	Whisper large-v2	逐词关闭	149.77s	4.01×	200.98s	350.75s	1.71×	—	—	9.94%
600s	Parakeet CUDA	置信度完整	164.01s	3.66×	200.98s	364.99s	1.64×	0.825	5%	10.67%
600s	Whisper large-v2	置信度完整	192.37s	3.12×	200.98s	393.35s	1.53×	0.747	12%	8.92%
600s	Multitalker Parakeet	单说话人模式	736.19s	0.82×	200.98s	937.17s	0.64×	—	—	14.57%
600s	VibeVoice	置信度完整	-	-	-	-	-	-	-	-
600s	Qwen3-ASR + 对齐	ASR 文本 + 对齐 · 4×150s	121.987s	4.92×	-	121.987s	4.92×	-	-	10.17%
600s	Whisper + 对齐	Whisper 文本 + 对齐 · 4×150s	181.520s	3.31×	-	181.520s	3.31×	-	-	8.64%
600s	Canary-1B-Flash	长音频 900s 未完成	-	-	-	-	-	-	-	-
600s	Canary-1B-v2	未跑（300s 已失败）	-	-	-	-	-	-	-	-
600s	Parakeet-TDT-1.1B	CUDA · 单次	643.768s	0.93×	-	643.768s	0.93×	-	-	16.95%
600s	Whisper large-v3	CUDA · 逐词开	182s	3.30×	-	182s	3.30×	-	-	12.99%
600s	Paraformer-en	未跑（300s 已失败）	-	-	-	-	-	-	-	-
600s	Granite Speech 2B	长音频 900s 未完成	-	-	-	-	-	-	-	-
600s	Granite Speech 8B	8GB 显存不足未测	-	-	-	-	-	-	-	-

片段	模型	配置	识别耗时	识别×	分离耗时	总耗时	总×	平均置信度	低置信占比	WER
600s	GLM-ASR-Nano-2512	长音频输出截断	-	-	-	-	-	-	-	-
600s	Fun-ASR-Nano-2512	长音频复读	-	-	-	-	-	-	-	-
600s	Index-Echo-S2TT-2B	Q8_0 仅文本 / 完整 10GB>8GB	-	-	-	-	-	-	-	-
600s	Granite Speech 5.0 470M	CUDA · CTC	2.03s	295.57×	-	2.03s	295.57×	-	-	11.86%
600s	Parakeet-TDT-0.6B-v3	CUDA · TDT	45.482s	13.19×	-	45.482s	13.19×	-	-	11.30%
600s	Nemotron 3.5 ASR 0.6B	600s 未完成	-	-	-	-	-	-	-	-
600s	MOSS-Transcribe-Diarize 0.9B	输出截断（仅 1053 词）	-	-	-	-	-	-	-	-
600s	Canary-Qwen 2.5B	未跑（300s 已失败）	-	-	-	-	-	-	-	-

模型简称：Parakeet CUDA = sherpa-onnx CUDA；Parakeet NPU = OpenVINO；Whisper = Faster-Whisper-XXL。

VibeVoice：30s 在 900s 上限超时，5/10min 未跑；5s 实测 27.39s（0.18×）。未完成项用 "-" 表示。

组合行（Qwen / Whisper + 对齐）都按**端到端墙钟**计，含模型加载：Qwen 加载 4.24s + 2.63s；

Whisper 30/300/600 的 XXL 墙钟为 30/92/176s（含约 26s 加载），再加对齐推理与 2.55s 对齐加载。

分离、置信度不适用，用 "-"；WER 来自 ASR 文本，词边界与拆分见附录。

Multitalker Parakeet：应用里只用于「选区重新识别」，worker 强制 single_speaker_mode=True，没有逐词时间戳与置信度；本表按这个实际用法测试，不代表它的多说话人能力。

新增候选模型均只做 **CUDA** 测试、未接入 SubFabric；30s 结果含模型加载，不能当稳态吞吐。表中 - 的原因：

Canary-1B-Flash 5/10min 在 900s 内未完成；Canary-1B-v2 300s 触发 CUDA device-side assert、600s 未跑；

Granite Speech 2B 5/10min 在 900s 内未完成；Paraformer-en 300s 触发 ONNX Mul 广播错误、600s 未跑。

Granite Speech 8B 未测试：8GB 显存明确不足，按要求记 -。

GLM-ASR-Nano 300s 输出错乱（WER 77.38%，不作为有效结果）、600s 截断；Fun-ASR-Nano 300s 只输出 120 字、

600s 出现 there, there... 复读，均不作为有效结果。两者 30s 结果有效。

Index-Echo-S2TT-2B-GGUF (Q8_0) 未测试：该 GGUF 只有文本 LLM backbone，缺 audio tower/connector，

llama.cpp 无法跑完整语音；完整 bf16 包约 10GB VRAM > 本机 8GB，按规则记 -。它只输出句级时间戳，

逐词需要源转写 + 对齐模型；Q8_0 没有音频能力，无法产生可对齐的转写。

Nemotron 3.5 600s 在 600s 上限内未完成；30s/300s 有效。

MOSS 0.9B 600s 只输出 1053 词（参考 1770 词），WER 44.63%，不作为有效结果；30s/300s 有效。

Canary-Qwen 2.5B 300s 只输出 480 字且内容错乱，600s 未跑；仅 30s 有效。

新增候选的逐词统一用 Qwen3-ForcedAligner，结果见附录。

关键结论

- **准确率**：Whisper large-v2 在 5/10 分钟都是第一（8.73% / 8.92%）；Parakeet CUDA 紧随其后（9.07% / 10.67%）。30 秒样本太小（82 词），NPU/Whisper 的 1.22% 与 CUDA 的 3.66% 只差 1–3 个词，不能当稳定结论。
- **速度**：NPU 最快（关闭置信度：5 分钟 25.1×、10 分钟 27.3×），Parakeet CUDA 次之（14.2× / 13.3×），Whisper large-v2 最慢（3.7× / 3.1×）。
- **置信度「完整」的代价**：Parakeet CUDA 从关闭到完整慢约 2.1×（30s）/3.6×（5、10min）；NPU 慢 1.5–1.9×。WER 完全不变（同一段解码文本），完整档只多出稳定性标记与更保守的置信度——为速度应关闭，为复核可疑句才开。
- **NPU 的准确率不可用于终稿**：WER 22.8%–23.0%，识别词数比参考少约 15%（会漏词）；适合粗剪/快速定位，不适合直接出稿。
- **说话人分离**：30s/5min/10min 实测 7.2s/116.1s/201.0s，与模型无关。开启后总倍率：10 分钟 NPU 2.69×、Parakeet CUDA 2.44×、Whisper 1.53×；5 分钟分别 2.34× / 2.19× / 1.51×。不需要说话人时应关闭。
- **逐词关闭**（仅 Faster-Whisper）：WER 变差（6.1% / 10.19% / 9.94%），速度没有稳定收益（5 分钟反而更慢）；不要关。
- **Multitalker Parakeet 0.6B**：按应用实际的「单说话人重识别」模式跑，30s/5min/10min 分别 34.4s / 281.3s / 736.2s（0.87× / 1.07× / 0.82×），WER 3.66% / 13.44% / 14.57%。比 Whisper/Parakeet 都慢，且没有逐词时间戳与置信度；它只在「选区重新识别」里有意义，不适合当批量转写引擎。
- **Qwen3-ASR 1.7B + Qwen3-ForcedAligner 0.6B**（独立部署，不接入 SubFabric）：30s/5min/10min

端到端 12.325s / 61.257s / 121.987s（2.43× / 4.90× / 4.92×），WER 2.44% / 9.07% / 10.17%；

词边界起始中位 80/80/70ms，200ms 内 92.4% / 94.7% / 93.8%。

- **Whisper large-v2（无逐词）+ Qwen3-ForcedAligner 0.6B**：端到端 33.558s / 96.013s / 181.520s

（0.89× / 3.12× / 3.31×），WER 1.22% / 10.08% / 8.64%；词边界起始中位 70/80/70ms，

200ms 内 92.5% / 91.3% / 92.3%。30s 被 XXL 约 26s 加载拖慢，长片段 Qwen 方案仍更快；

WER 各有胜负（Whisper 在 30s/10min 更好，Qwen 在 5min 更好）。

- **Whisper large-v3**：30s/5min/10min 24s / 74s / 182s（1.25× / 4.05× / 3.30×），

WER 3.66% / 10.19% / 12.99%。5min 比 large-v2 快，但 10min 更慢、WER 更差；本机不作为替代。

- **Parakeet-TDT-1.1B**：14.6s / 115.963s / 643.768s（2.05× / 2.59× / 0.93×），

WER 3.66% / 12.21% / 16.95%。比 0.6B 更慢且 WER 更高，本机没有升级收益。

- **30s 新候选**：Canary-1B-v2 7.571s（3.96×，WER 4.88%）最快；Paraformer-en 9.073s（3.31×，WER 8.54%）；

Granite Speech 2B 12.129s（2.47×，WER 3.66%）；Canary-1B-Flash 34.173s（0.88×，WER 3.66%，

被约 10.6s 加载拖慢）。长片段均未完成，见下方 - 说明；Granite 8B 因 8GB 显存明确不足未测。

- **GLM-ASR-Nano-2512**：30s 8.764s（3.42×，WER 6.10%）有效；300s 输出错乱（WER 77.38%）、

600s 截断，长音频不可用（8K context）。

- **Fun-ASR-Nano-2512**：30s 19.014s（1.58×，WER 3.66%，加载 14.17s 占大头）有效；

300s 只输出 120 字、600s 复读，整段长音频不可用，需要它自己的 streaming/cache 分块。

- **Index-Echo-S2TT-2B-GGUF Q8_0**：Q8_0 只有 2.08GB 文本 backbone，没有 audio tower/connector，

不能做语音；完整 bf16 包需约 10GB VRAM > 8GB，按规则不测试，三档记 -。它是中→英/日/西

的语音翻译，不是英语 ASR；句级时间戳，逐词需源转写 + 对齐模型，本次无逐词数值。

- **Parakeet-TDT-0.6B-v3**：30s/5/10min 4.146s / 11.348s / 45.482s（7.24× / 26.44× / 13.19×），

WER 2.44% / 10.64% / 11.30%。30s 比 v2 好，5/10min 略差但快 1.8–2 倍；**本轮最强新候选。**

- **Granite Speech 5.0 470M**：2.215s / 1.922s / 2.03s（13.54× / 156.09× / 295.57×），

WER 6.10% / 12.77% / 11.86%。速度极端但 WER 不如 Parakeet/Whisper，适合超快粗剪，不适合终稿。

- **Nemotron 3.5 ASR 0.6B**：30s/5min 4.868s / 18.737s（6.16× / 16.01×），WER 8.54% / 15.23%；

600s 未完成。多语种流式候选，批处理准确率不占优。

- **MOSS-Transcribe-Diarize 0.9B**：30s/5min 18.274s / 185.161s（1.64× / 1.62×），

WER 3.66% / 9.18%；600s 输出截断（WER 44.63% 无效）。唯一带说话人分离/段级时间戳的候选，

适合多说话人场景；作为普通 ASR 太慢。

- **Canary-Qwen 2.5B**：30s 46.088s（0.65×），WER 3.66%；300s 输出错乱、600s 未跑。

8GB 能加载但太慢，长音频不可用。

- **VibeVoice**：5 秒音频 27.4s；30 秒在 900s 上限仍未完成，5/10 分钟未跑。当前机器（8GB 显存）不适合 30 秒以上整段识别。

推荐

- 终稿：**Whisper large-v2（置信度完整或快速，逐词开）**，接受 1.5–1.6× 实际倍率。
- 需要快、能接受约 1–2 个百分点 WER：**Parakeet CUDA + 置信度关闭**（10 分钟 13.3× 识别、2.44× 含说话人分离）。
- 只在找素材/粗剪时用 **Parakeet NPU**；不要用于终稿。
- 说话人区分按需开；开了就预期总时间增加 2–3 分钟（10 分钟素材）。

口径与限制

- 30 秒一档包含模型加载，不代表稳态吞吐；5/10 分钟已基本摊薄加载。
- 每档只跑一次，没有重复测量与误差棒；GPU 温度/后台负载会造成几个百分点波动。
- 置信度是各引擎自评（0–1），不同引擎的分数不可直接横向比较；VibeVoice 没有逐句置信度。
- 说话人开/关不改变识别文本与置信度，只改总耗时；分离只测一次，按同一时长加到每个模型上。
- 未包含：双引擎（走独立「双引擎分工」页）、云端必剪/剪映（非本地）、whisper.cpp large-v3-turbo 与 Parakeet Vulkan（未安装）。
- WER 参考取每句开始时间 < 片段长度的 Default 行，末句可能越过边界几个词；这是横评口径，不是对齐级评测。

附：Whisper / Qwen3-ASR + Qwen3-ForcedAligner 方案对比（独立部署，不接入 SubFabric）

- **两套方案**:

1. Qwen/Qwen3-ASR-1.7B-hf（4.08GB）只生成文本 → Qwen/Qwen3-ForcedAligner-0.6B-hf（1.84GB）出词级时间；

2. Whisper large-v2（Faster-Whisper-XXL，word_timestamps=False）只生成文本 → 同一个对齐器出词级时间。

- **环境**：CUDA bf16，RTX 4060 Laptop 8GB；asr/runtime-vibevoice 的 CUDA PyTorch 2.14.0+cu126 +

隔离的 Transformers 5.20.2；脚本在 _test/maintenance/qwen-asr/，没有 CPU 兜底，也未改 SubFabric。

- **方法**：30s 单次；5/10min 的对齐按 150s 切块（300s 单次对齐会把尾部约 20s 的词挤到最后一个

时间戳）。Qwen 的 ASR 也按 150s 分块；Whisper 跑完整片段后，用它自己的 segment 边界在约

150/300/450s 处切音频，文本随 segment 分配，避免在词中间切。

方案	片段	ASR 推理	对齐	加载	端到端	实时倍率	WER	边界覆盖	起始中位/≤200ms
Qwen3-ASR 1.7B	30s	5.262s	0.193s	6.87s	12.325s	2.43×	2.44%	97.5%	80ms / 92.4%
Qwen3-ASR 1.7B	5min	53.297s	1.090s	6.87s	61.257s	4.90×	9.07%	92.0%	80ms / 94.7%
Qwen3-ASR 1.7B	10min	113.085s	2.032s	6.87s	121.987s	4.92×	10.17%	91.5%	70ms / 93.8%
Whisper large-v2	30s	4.0s*	1.008s	28.55s	33.558s	0.89×	1.22%	98.8%	70ms / 92.5%
Whisper large-v2	5min	66.0s*	1.463s	28.55s	96.013s	3.12×	10.08%	89.8%	80ms / 91.3%
Whisper large-v2	10min	150.0s*	2.970s	28.55s	181.520s	3.31×	8.64%	91.8%	70ms / 92.3%

端到端 = ASR 推理 + 对齐推理 + 加载。Qwen 加载 = ASR 4.24s + 对齐 2.63s；Whisper 加载 =

XXL 约 26s + 对齐 2.55s。Whisper 的 ASR 推理（*）由实测墙钟 30/92/176s 减去 26s 加载估算，

有约 1–2s 的不确定度，所以 30s 档尤其只能看量级。

边界覆盖 = ASR 文本与参考高亮词匹配上的词数 / 参考词数，包含 ASR 文本与参考文本的差异。

方案	片段	起始中位	起始≤200ms	结束中位	结束≤200ms	覆盖
Qwen3-ASR	30s	80ms	92.4%	40ms	92.4%	97.5%
Qwen3-ASR	5min	80ms	94.7%	50ms	93.0%	92.0%
Qwen3-ASR	10min	70ms	93.8%	50ms	91.6%	91.5%
Whisper	30s	70ms	92.5%	40ms	93.8%	98.8%
Whisper	5min	80ms	91.3%	50ms	90.2%	89.8%
Whisper	10min	70ms	92.3%	50ms	90.9%	91.8%

- **速度**：Qwen 组合 2.43× / 4.90× / 4.92×；Whisper 组合 0.89× / 3.12× / 3.31×。

Whisper 的 30s 被 XXL 约 26s 加载拖慢；5/10min Qwen 仍快约 1.3–1.6 倍。

- **准确率**：Whisper 文本 WER 1.22% / 10.08% / 8.64%，Qwen 2.44% / 9.07% / 10.17%——

30s/10min Whisper 更好，5min Qwen 更好；30s 只有 82 词，不应当稳定结论。

- **词边界**：两套方案中位都是 70–80ms，5/10min 约 91–95% 的匹配词起始边界在 200ms 内；

约 257s 音乐/停顿处仍有 3–4 个词偏早（最坏约 15s），看中位/P90/200ms 覆盖率更符合听感。

- **限制**：参考是 ASS 卡拉 OK 显示时间，不是帧级人工标注；只测英语；Whisper 的加载估算与

分块边界会带来误差；ASR 错词/漏词会拉低边界覆盖率。模型未接入应用。

附：新增候选模型测试说明

测试脚本与原始输出在 _test/maintenance/candidates/；所有模型都只用 CUDA，未接入 SubFabric。

模型	权重 / 运行时	30s（总耗时 / WER）	5min	10min
Canary-1B-Flash	3.54GB `.nemo` / NeMo	34.173s / 3.66%	-	-
Canary-1B-v2	3.92GB safetensors / Transformers bf16	7.571s / 4.88%	-	-
Parakeet-TDT-1.1B	4.28GB `.nemo` / NeMo	14.6s / 3.66%	115.963s / 12.21%	643.768s / 16.95%
Whisper large-v3	3.09GB CTranslate2 / Faster-Whisper-XXL	24s / 3.66%	74s / 10.19%	182s / 12.99%
Paraformer-en	230MB int8 ONNX / sherpa-onnx CUDA	9.073s / 8.54%	-	-
Granite Speech 2B	~6GB 分片 / Transformers bf16	12.129s / 3.66%	-	-
Granite Speech 8B	~16GB 权重 / 未加载	-	-	-
GLM-ASR-Nano-2512	4.5GB safetensors / Transformers bf16	8.764s / 6.10%	-	-
Fun-ASR-Nano-2512	1.97GB model.pt / FunASR	19.014s / 3.66%	-	-
Index-Echo-S2TT-2B-GGUF Q8_0	2.08GB 文本 backbone / 无音频塔；完整包 ~10GB	-	-	-
Granite Speech 5.0 470M	0.95GB safetensors / Transformers CTC	2.215s / 6.10%	1.922s / 12.77%	2.03s / 11.86%
Parakeet-TDT-0.6B-v3	2.5GB safetensors / Transformers TDT	4.146s / 2.44%	11.348s / 10.64%	45.482s / 11.30%
Nemotron 3.5 ASR 0.6B	2.55GB safetensors / Transformers RNNT	4.868s / 8.54%	18.737s / 15.23%	-
MOSS-Transcribe-Diarize 0.9B	1.82GB safetensors / 自定义 Transformers	18.274s / 3.66%	185.161s / 9.18%	-
Canary-Qwen 2.5B	5.1GB safetensors / NeMo SALM	46.088s / 3.66%	-	-

- **Canary-1B-Flash**：30s 有效（加载 10.6s + 推理 23.573s）；300/600s 在 900s 内未完成。
- **Canary-1B-v2**：30s 有效（加载 5.32s + 推理 2.251s）；300s 触发 CUDA device-side assert，600s 未跑。
- **Parakeet-TDT-1.1B**：三档均完成；600s 推理 630.998s、加载 12.77s，已接近实时。
- **Whisper large-v3**：三档均完成；30s/5min 含 XXL 加载；WER 比 large-v2 更差。
- **Paraformer-en**：30s 有效（加载 3.7s + 推理 5.373s）；300s ONNX Mul 广播错误、600s 未跑。
- **Granite Speech 2B**：30s 有效（加载 5.4s + 推理 6.729s）；300/600s 在 900s 内未完成。
- **Granite Speech 8B**：8GB 显存明确不足，按要求不测试，结果记 -。
- **GLM-ASR-Nano-2512**：30s 有效（加载 4.37s + 推理 4.394s）；300s 输出错乱（WER 77.38%）、

600s 只输出 379 字符，长音频不可用（8K context）。

- **Fun-ASR-Nano-2512**：30s 有效（加载 14.17s + 推理 4.844s）；300s 只输出 120 字、

600s 出现 there, there... 复读；需要 streaming/cache 分块，整段调用不可用。

- **Index-Echo-S2TT-2B-GGUF Q8_0**：Q8_0 只是文本 LLM backbone，audio tower/connector 不在

GGUF 里，llama.cpp 不能跑语音；完整 bf16 包约 10GB VRAM > 8GB，未测试、三档记 -。

它是中→英/日/西 S2TT，不是英语 ASR，只给句级时间戳；逐词需用完整包源转写再交给对齐模型，

本次因显存不足没有可对齐转写，故无逐词数值。

- **Granite Speech 5.0 470M**：CTC，三档均完成；加载 1.27–1.39s，推理 0.65–0.83s，

速度极高但 WER 6.10/12.77/11.86%，适合粗剪/超快转写，不适合终稿。

- **Parakeet-TDT-0.6B-v3**：三档均完成；加载 2.98–3.16s，推理 1.17/8.19/42.32s，

WER 2.44/10.64/11.30%；本轮综合最好的新候选。

- **Nemotron 3.5 ASR 0.6B**：30s/300s 有效；600s 在 600s 上限内未完成，记 -。
- **MOSS-Transcribe-Diarize 0.9B**：30s/300s 有效；300s 有说话人标签和段级时间戳，

但 1.62×；600s 只输出 1053 词、WER 44.63% 无效，记 -。它的价值在多说话人，不是普通 ASR。

- **Canary-Qwen 2.5B**：仅 30s 有效（加载 21.18s + 推理 24.908s，0.65×）；

300s 只输出 480 字且内容错乱、600s 未跑。8GB 可加载但太慢，长音频不可用。

逐词对齐结果（Qwen3-ForcedAligner）

模型	片段	预测词数	匹配词数	覆盖率	起始中位	起始≤200ms	结束中位
Granite 5.0 470M	30s	81	77	95.1%	70ms	92.2%	40ms
Granite 5.0 470M	5min	837	740	88.1%	90ms	79.5%	60ms
Parakeet-TDT-0.6B-v3	30s	81	78	96.3%	80ms	92.3%	40ms
Parakeet-TDT-0.6B-v3	5min	856	775	92.3%	90ms	79.7%	60ms
Nemotron 3.5 0.6B	30s	81	75	92.6%	80ms	92.0%	40ms
Nemotron 3.5 0.6B	5min	845	721	85.8%	90ms	80.3%	60ms
MOSS 0.9B	30s	79	78	96.3%	70ms	92.3%	40ms
MOSS 0.9B	5min	882	766	91.2%	80ms	83.0%	60ms
Canary-Qwen 2.5B	30s	79	78	96.3%	70ms	92.3%	40ms

- 10min 没有做逐词：Qwen3-ForcedAligner 官方建议单段 ≤5min；10min 需要按转写切两段，

但候选模型没有词级时间可用来切，强行切会污染结果。表中只列 30s/5min。

- 覆盖率按参考 ASS 高亮词计算；ASR 错词/漏词会拉低覆盖率，不等于对齐器本身失败。