WhisperX + MDX + 说话人分离：补充评测

同一素材、同一 30s / 5min / 10min 切片；对比 SubFabric 当前 Whisper large-v2 + 我们已有的说话人分离

素材	How I Saved the World's Largest Minecraft Server.webm（前 30 秒 / 5 分钟 / 10 分钟）
参考	精校过前两小时的字幕.ass（Default 英文行去标签/逐词重复；说话人取中文字幕 [name]）
机器	RTX 4060 Laptop 8GB + Intel Arc 核显 + Intel AI Boost NPU；Windows；NVIDIA 驱动
口径	WER 忽略大小写/标点/连字符，数字归一；WhisperX 与 SubFabric 都开 MDX 人声分离；都指定 6 个说话人。

结论摘要

开着 MDX 后，WhisperX 的 ASR 有竞争力：30s / 5min / 10min WER 为 1.19% / 8.59% / 9.23%；SubFabric 同口径复跑为 1.19% / 9.44% / 11.31%。30s 持平，5/10min WhisperX 分别低 0.85 / 2.08pp。**但 WhisperX 整体慢约 3.3×：**总耗时 47.4s / 497s / 997s（含说话人分离），SubFabric 为 16.1s / 141s / 299s；主要慢在 pyannote 分离（35.7s / 455s / 926s）。**说话人分离 SubFabric 更好：**句级映射准确率 5min 73.2% / 10min 65.1%，WhisperX 为 64.5% / 62.9%；两者检测到的簇数接近（5min 均为 4，10min 均为 6）。**pyannote VAD 已修：**SpeechBrain LazyModule 的 dunder 属性不再触发 inspect 递归；30/300s 通过，600s 单次 VAD 仍超时，改为 2×300s 后 WER 9.23%。

本机结果（总耗时含说话人分离）

方案	30s WER	5min WER	10min WER	总耗时 30s / 5 / 10min	说话人准确率 5 / 10min
WhisperX 3.4.2 + MDX + pyannote	1.19%	8.59%	9.23%	47.4 / 497 / 997s	64.5% / 62.9%
SubFabric • XXL large-v2 + MDX + sherpa	1.19%	9.44%	11.31%	16.1 / 141 / 299s	73.2% / 65.1%
2026-10-21 报告 • XXL + MDX（无说话人分离）	1.22%	8.73%	8.92%	36.6 / 198 / 393s	—

WER：MDX 把差距拉回来了

片段	WhisperX WER	SubFabric WER	差值（WhisperX − SubFabric）
30s	1.19%	1.19%	0.00pp
5min	8.59%	9.44%	−0.85pp
10min	9.23%	11.31%	−2.08pp

负值表示 WhisperX 更好。WhisperX 600s 为 2×300s 切分后拼接；30s 两者完全相同。

耗时分解（秒）

片段	WhisperX ASR+对齐	WhisperX 分离	WhisperX 总	SubFabric ASR	SubFabric 分离	SubFabric 总
30s	11.7	35.7	47.4	10.6	5.5	16.1
5min	42.2	454.8	497.0	47.8	93.4	141.2
10min	71.1	925.7	996.8	120.9	178.1	299.0

WhisperX 分离 = pyannote 3.1（GPU）；SubFabric 分离 = sherpa-onnx（CPU）。WhisperX 的 ASR 时间为已加载模型后的转写，SubFabric XXL 的时间含模型加载；总耗时 = ASR + 对齐 + 分离 + 分配。

说话人分离：谁更像参考

片段	参考人数	WhisperX 检测 / 准确率	SubFabric 检测 / 准确率
30s	1	5 / 22.2%*	4 / 44.4%*
5min	5	4 / 64.5%	4 / 73.2%
10min	6	6 / 62.9%	6 / 65.1%

准确率：按句级最大重叠取系统说话人，再用最优标签映射统计；覆盖 100%。不是帧级 DER。* 30s 参考只有 1 个说话人，6 簇分离的准确率不具比较意义。

结论：SubFabric 的 sherpa 分离在 5/10min 都更准；WhisperX 的 pyannote 在 5min 少分 1 人（4 vs 5），10min 人数对但边界更碎。

pyannote VAD 修复：从 RecursionError 到可用

症状：WhisperX CLI 一开 --vad_method pyannote 就报 RecursionError；直接构造 Pyannote 也可能在 diarization 的 Pipeline.from_pretrained 处复现。设 TORCH_FORCE_NO_WEIGHTS_ONLY_LOAD=1 只能解决 torch.load 的 weights_only 报错，解决不了递归。

根因：pyannote 的 checkpoint 走 PyTorch Lightning 的 load_from_checkpoint；Lightning 的 _restricted_classmethod_impl 用 inspect.stack() 判断是否 scripting，inspect.getmodule() 走到 SpeechBrain 的 LazyModule，触发 speechbrain.utils.importutils.LazyModule.__getattr__ 的递归解析。

修复：在 import whisperx / whisperx.diarize 之前，把 LazyModule 的 __file__、__spec__ 等 dunder 属性直接抛 AttributeError；普通属性仍走原逻辑。完整文件见 docs/whisperx-2026-10-23/mdx-diar/pyannote_fix.py。

```
os.environ.setdefault("TORCH_FORCE_NO_WEIGHTS_ONLY_LOAD", "1")
import pyannote.audio.pipelines
from speechbrain.utils import importutils
_orig = importutils.LazyModule.__getattr__
def safe(self, name):
    if name in DUNDERS: raise AttributeError(name)
    return _orig(self, name)
importutils.LazyModule.__getattr__ = safe
```

验证结果

- 30s / 300s：pyannote VAD + pyannote diarization 全流程通过，不再递归。
- 600s：单次 pyannote VAD 在本机 >40min 未返回（日志停在 VAD 前），改用 2×300s 后通过；拼接后 WER 9.23%。这是长度/资源限制，不是补丁失效。
- VAD 参数：300s 从“无 MDX + Silero”的 19.51% 到“MDX + pyannote”的 8.59%，同时变了两个条件，不能单独归因；但说明人声分离与 VAD 都影响结果，不能只测其中一个。

环境与复现口径

WhisperX	3.4.2；faster-whisper 1.2.0；CTranslate2 4.4.0
PyTorch	2.7.1+cu126；torchaudio 2.7.1；Transformers 4.56.1
ASR	Whisper large-v2，float16，batch_size=8，language=en
VAD / 分离	pyannote segmentation-3.0 / pyannote speaker-diarization-3.1；6 speakers
对齐	wav2vec2 base 960h
SubFabric	Faster-Whisper-XXL large-v2 + MDX；asr/diarize.py（sherpa-onnx），6 speakers

结论与建议

- **质量：**WhisperX 的 ASR 在 MDX 后已经能与 SubFabric 打平甚至略好：30s 相同，5/10min 分别低 0.85 / 2.08pp。此前 19.51% / 14.03% 的结论来自“无 MDX”，不能代表 WhisperX 的真实水平。
- **成本：**不能直接替换当前流水线：WhisperX 总耗时约为 SubFabric 的 3.3×，其中 pyannote 说话人分离就占 35.7s / 455s / 926s；SubFabric 的 sherpa 分离是 5.5s / 93.4s / 178.1s。
- **说话人：**说话人分离 SubFabric 更准：5min 73.2% vs 64.5%，10min 65.1% vs 62.9%。WhisperX 的 pyannote 在 5min 少分 1 人，边界也更碎；如果只想要更准的说话人，现有 sherpa 更合适。
- **建议：**如果目标是 ASR 质量、且 GPU 时间充足：WhisperX + MDX 值得保留作为候选；如果目标是完整字幕流水线：继续用 SubFabric，或“WhisperX 转写 + sherpa 说话人分离”的组合，先实测再决定。

限制

- 本轮固定 6 个说话人；30s 参考只有 1 人，6 簇分离的准确率无意义。真实使用应让用户填人数或走自动聚类。
- 说话人准确率是句级最优标签映射，不是帧级 DER；参考说话人来自中文字幕 [name]，边界与英文句不完全对齐。
- SubFabric 本轮复跑 WER 9.44% / 11.31%，与 2026-10-21 报告的 8.73% / 8.92% 有 0.7 / 2.4pp 差异；差异原因尚未完全定位（报告可能含额外分句/清洗）。本对比统一用同一参考、同一 MDX 人声，故相对差值仍可比。
- 600s 的 WhisperX 使用 2×300s 切分；单次 600s pyannote VAD 在本机 >40min 未返回。SubFabric 的 600s 是整段。
- 单次运行、单机 RTX 4060 Laptop 8GB；未做多次取均值，未接入 SubFabric。

文件与状态

原始 JSON、说话人分离结果、逐句准确率与补丁：docs/whisperx-2026-10-23/mdx-diar/（results.json、hyp-*.json、whisperx-diar-*.json、subfabric-diar-*.json、speaker-eval-*.json、pyannote_fix.py）。

状态：已完成且已验证（本机单次，RTX 4060 Laptop 8GB）；未接入生产；GitHub 尚未提交（本轮只新增评测报告与数据）。